



Università di Catania

UNIVERSITÀ DEGLI STUDI DI CATANIA
DIPARTIMENTO DI MATEMATICA E INFORMATICA
CORSO DI LAUREA MAGISTRALE IN INFORMATICA.

Relazione Progetto *Deep Learning: Core Models and Methods*

Sistema di Supporto alla Diagnosi dell'Alzheimer tramite Deep Learning

Gruppo: *NeuroVisionDL*

Alessia Maccarrone
matricola **1000084712**

Martina Brancaforte
matricola **1000015074**

Massimiliano Cassia
matricola **1000016487**

Prof. Giovanni Maria Farinella
Prof. Francesco Ragusa

Anno Accademico 2025/2026

Indice dei contenuti

Indice dei contenuti	i
1 Introduzione e Obiettivi	2
1.1 Fasi	3
2 Dataset	5
2.1 Organizzazione e Gestione dei Dati	5
2.2 Gestione dello Sbilanciamento e Data Augmentation	6
2.3 Pre-processing e Standardizzazione	7
2.4 Suddivisione del Dataset (Data Split)	8
3 Metodologia: Architetture, Strategie e Scelte Tecniche	9
3.1 La sfida: Classificazione Binaria vs Multiclasse	9
3.2 Analisi comparativa dei modelli scelti	10
3.3 La strategia del Transfer Learning	10
3.4 Configurazione dell'addestramento	11
4 Esperimenti e Analisi delle Variabili Influenzanti	12
4.1 Ambiente di Sviluppo e Hardware	12
4.2 Protocollo degli Esperimenti	12
4.3 Fasi di Addestramento e Fine-Tuning	13
4.3.1 Esperimento Baseline (MLP)	13
4.3.2 Configurazione della Classificazione Binaria (Fase 1)	13
4.3.3 Esperimento Transfer Learning e Feature Extraction (Fase 2)	15
4.3.4 Ottimizzazione tramite Fine-Tuning	15
5 Valutazione dei Risultati e Analisi delle Performance	16
5.1 Analisi delle Metriche Globali	16
5.2 Interpretazione della Confusion Matrix	17
5.2.1 La sfida della "Zona Grigia"	18
5.3 La Curva ROC (One-vs-Rest)	18
5.4 Confronto tra le Architetture	19
6 Demo: NeuroVision DL	20
6.1 Funzionamento e Pipeline di Pre-processing	20
6.2 Selezione Dinamica delle Architetture	20
6.3 Visualizzazione dei Risultati e Confidenza Clinica	21

7	Conclusione	23
7.1	Considerazioni Finali sulle Architetture	23
7.2	Sviluppi Futuri e Prospettive di Ricerca	24
7.2.1	Integrazione Multimodale (Dati Clinici e Demografici):	24
7.2.2	Explainable AI (Intelligenza Artificiale Spiegabile - XAI):	24
7.2.3	Analisi Volumetrica 3D e Studi Longitudinali:	24

L'invecchiamento della popolazione globale ha reso le malattie neurodegenerative, e in particolare l'***Alzheimer***, una delle sfide sanitarie più urgenti del nostro secolo e che con l'aumento dell'aspettativa di vita, i casi di demenza sono destinati a raddoppiare nei prossimi vent'anni.

La diagnosi definitiva, spesso, avviene quando il danno neuronale è già esteso, infatti l'Intelligenza Artificiale non si pone come un sostituto del medico, ma come un sofisticato strumento di supporto. Il nostro progetto nasce dalla volontà di applicare le potenzialità del Deep Learning a una delle sfide più complesse della medicina moderna: la diagnosi del morbo di Alzheimer. L'obiettivo che ci siamo posti come gruppo non è stato semplicemente quello di "far funzionare un algoritmo", ma di costruire una pipeline completa e rigorosa che simuli un reale processo di ricerca e sviluppo.

Abbiamo scelto di lavorare su scansioni di risonanza magnetica (MRI) perché crediamo che l'intelligenza artificiale possa fungere da "secondo occhio" per il neurologo, aiutando a individuare quei pattern sottili di atrofia cerebrale che distinguono i vari stadi della demenza. In questo lavoro, abbiamo cercato di bilanciare l'efficienza computazionale con l'accuratezza clinica, dimostrando come sia possibile gestire l'intero ciclo di vita di un modello: dalla pulizia del dato grezzo fino alla creazione di un'interfaccia utente interattiva.

Il progetto si colloca nell'intersezione tra la neurologia clinica e l'intelligenza artificiale avanzata. Tradizionalmente, l'analisi delle **immagini MRI per la diagnosi dell'Alzheimer** si è basata su misurazioni manuali o algoritmi di visione artificiale "classici", che richiedevano l'estrazione manuale di caratteristiche (come lo spessore della corteccia o il volume dell'ippocampo).

Il Deep Learning, e in particolare l'uso delle **Reti Neurali Convolutionali (CNN)** e i **Vision Transformer (ViT)**, hanno rivoluzionato questo paradigma: questi modelli apprendono autonomamente una gerarchia di caratteristiche visive, identificando alterazioni strutturali che potrebbero sfuggire all'occhio umano.

Per affrontare il problema in modo metodico, il progetto è stato strutturato in due fasi di complessità crescente: ha rivoluzionato questo paradigma: questi modelli sono in grado di apprendere autonomamente una gerarchia di caratteristiche visive, identificando alterazioni strutturali e micro-pattern morfologici che potrebbero sfuggire anche all'occhio umano più esperto.

1.1 Fasi

- **Fase 1 - Diagnosi Binaria:** Il task iniziale si concentra sulla classificazione fondamentale tra paziente "Sano" (NonDemented) e "Affetto". In questa fase, tutte le varianti della patologia vengono accorpate in un'unica macro-classe per stabilire una solida baseline diagnostica.
- **Fase 2 - Classificazione Multiclasse:** L'obiettivo si sposta su una classificazione granulare dello stadio degenerativo. Sono state analizzate quattro classi distinte che rappresentano il continuum della patologia.

Abbiamo infatti analizzato *quattro classi distinte* che rappresentano il continuum della patologia:

- **Non-Demented:** Il gruppo di controllo, fondamentale per definire i parametri di normalità cerebrale.
- **Very Mild Demented:** Rappresenta la fase più critica per la diagnosi precoce, dove le alterazioni sono minime e spesso confuse con il normale invecchiamento.
- **Mild Demented:** Una fase di declino cognitivo moderato ma evidente, dove i pattern di atrofia iniziano a diventare spazialmente definiti.
- **Moderate Demented:** Lo stadio più avanzato della patologia presente nel dataset, dove i danni strutturali sono macroscopici e la rete deve dimostrare la massima precisione.




Figura 1.1: Esempi MRI per classi.

Lavorare su queste **quattro classi** significa sfidare il modello non solo a riconoscere la malattia, ma a comprenderne l'evoluzione temporale.

Questo *approccio multiclasse* è ciò che rende il progetto ambizioso: l'obiettivo non è solo identificare il paziente affetto da Alzheimer, ma fornire uno strumento di stadiazione che possa aiutare i medici a pianificare interventi terapeutici personalizzati in base alla gravità del deterioramento rilevato.

La scelta dei dati ha rappresentato il pilastro fondamentale del nostro lavoro. Abbiamo deciso di affidarci alla *piattaforma Kaggle*, punto di riferimento mondiale per la scienza dei dati, selezionando l'**Augmented Alzheimer MRI Dataset**.

2.1 Organizzazione e Gestione dei Dati

Al fine di garantire la riproducibilità del nostro lavoro e mantenere un ambiente di sviluppo pulito, abbiamo strutturato i dati seguendo standard consolidati. Le immagini grezze scaricate dalla piattaforma Kaggle sono state isolate e conservate in una directory dedicata denominata **data/raw**, preservando la loro integrità originale.

A differenza degli approcci classici che prevedono il salvataggio fisico delle immagini pre-processate in una cartella separata, abbiamo optato per una pipeline dinamica per l'addestramento. Tramite le *librerie di PyTorch* (`torchvision.transforms`), le trasformazioni vengono applicate al volo direttamente sui tensori durante il caricamento dei batch in memoria. Questo approccio *ottimizza lo spazio di archiviazione e velocizza gli esperimenti*.

Inoltre, per gestire in modo flessibile le due fasi del progetto senza duplicare i dati fisici, abbiamo implementato una classe personalizzata, denominata **AlzheimerDataset**, che eredita da `torch.utils.data.Dataset`. Questa classe si occupa del re-mapping dinamico delle etichette in fase di caricamento:

- **Fase 1 (Binaria):** La classe `NonDemented` (sano) viene mappata all'intero 0, mentre tutte le altre forme di demenza vengono raggruppate e mappate all'intero 1 (affetto).
- **Fase 2 (Multiclasse):** Viene mantenuta la mappatura originale (da 0 a 3) alle rispettive quattro classi.

2.2 Gestione dello Sbilanciamento e Data Augmentation

Nella nostra analisi ci siamo confrontati con una sfida metodologica tipica dei dati medici: *lo sbilanciamento delle classi*.

In una distribuzione clinica reale, i pazienti **sani (NonDemented)** sono numericamente dominanti, mentre i casi di **demenza avanzata (Moderate Demented)** sono rari. Un modello addestrato solo su dati grezzi non bilanciati rischierebbe di cadere nell'errore della *"previsione maggioritaria"*, ignorando i casi patologici più gravi pur di mantenere un'accuratezza complessiva alta.

Per ovviare a questo problema, abbiamo sfruttato la natura **"Augmented"** del dataset di Kaggle, in cui il numero di campioni per le classi minoritarie è stato incrementato artificialmente fino a raggiungere un bilanciamento ottimale. Per garantire la coerenza anatomica delle risonanze magnetiche, abbiamo evitato l'introduzione di ulteriori trasformazioni geometriche irrealistiche (come i capovolgimenti verticali o speculari) all'interno del nostro script PyTorch, affidandoci all'augmentation originale fornita dal dataset.




Figura 2.1: Distribuzione Dataset

2.3 Pre-processing e Standardizzazione

Per rendere le immagini leggibili e ottimizzate per le Reti Neurali Convoluzionali (CNN) e i Vision Transformer (ViT), abbiamo implementato una fase di standardizzazione rigorosa. La composizione delle trasformazioni (**transforms.Compose**) include i seguenti passaggi:

- Tutte le scansioni sono state ridimensionate alla risoluzione di **224x224 pixel**. Questo formato standard rappresenta il miglior compromesso tra ricchezza di dettagli morfologici e sostenibilità computazionale.
- Abbiamo applicato una conversione in formato tensoriale (**ToTensor()**) e una *normalizzazione* dei valori dei pixel. La **normalizzazione** è basata sulla media ([0.485, 0.456, 0.406]) e sulla **deviazione standard** ([0.229, 0.224, 0.225]) del dataset ImageNet. Questo passaggio è fondamentale per garantire che la rete operi su una distribuzione di dati stabile, accelerando la convergenza durante le fasi di Transfer Learning.




Figura 2.2: Normalizzazione Dataset

2.4 Suddivisione del Dataset (Data Split)

Per valutare in modo onesto l'efficacia dei nostri modelli e simulare un reale contesto clinico, abbiamo implementato una rigorosa suddivisione del dataset utilizzando la funzione **randomsplit** di PyTorch.

Al fine di *garantire la totale riproducibilità degli esperimenti*, è stato fissato un seed generatore (`manualeseed(42)`). Il dataset è stato frammentato in **tre** sottoinsiemi distinti:

- **Training Set (70%):** Utilizzato per l'apprendimento e l'aggiornamento dei pesi della rete.
- **Validation Set (15%):** Utilizzato per monitorare le metriche alla fine di ogni epoca; questo set è fondamentale per innescare le procedure di Early Stopping e Learning Rate Scheduling implementate nel nostro motore di addestramento.
- **Test Set (15%):** Questo sottoinsieme è rimasto rigorosamente isolato durante tutta la fase di sviluppo e addestramento, venendo utilizzato esclusivamente per il calcolo delle metriche di benchmark finali. Questa separazione garantisce che i risultati presentati siano rappresentativi della capacità del modello di generalizzare su immagini (e quindi ipotetici pazienti) mai viste prima.

3 Metodologia: Architetture, Strategie e Scelte Tecniche

In questa sezione descriviamo il percorso che ci ha portato alla costruzione del nostro sistema di classificazione. Non ci siamo limitati a testare un singolo modello, ma abbiamo messo a confronto tre filosofie architettoniche differenti per capire quale fosse la più adatta al delicato compito della diagnosi medica.

3.1 La sfida: Classificazione Binaria vs Multiclasse

Il nostro lavoro si è sviluppato su due fronti. Abbiamo iniziato con la **Classificazione Binaria**, un approccio propedeutico volto a distinguere semplicemente i pazienti sani dai malati. Una volta stabilita la solidità del metodo, siamo passati alla **Classificazione Multiclasse**, dove il modello deve imparare a discriminare tra *quattro stadi*: **Non Demented, Very Mild, Mild e Moderate**. Mentre la **binaria** ci ha dato la prova di *fattibilità*, la **multiclasse** ha rappresentato la vera sfida clinica, richiedendo al modello di identificare i *sottili cambiamenti morfologici* che segnano il passaggio da uno stadio all'altro della malattia.

- **Vision Transformer (ViT-B/16)**: Per confrontare le classiche CNN con i modelli State-of-the-Art, abbiamo introdotto il Vision Transformer. Elaborando le immagini in "patch" di dimensione 16x16 e usando il meccanismo di attenzione globale, rappresenta la frontiera della ricerca attuale, sebbene richieda molta più memoria VRAM rispetto alle reti precedenti.

3.2 Analisi comparativa dei modelli scelti

Ognuno degli algoritmi scelti risponde a un'esigenza specifica:

- **MLP (Multi-Layer Perceptron):** È la rete neurale nella sua forma più basilare, composta da strati densi (Fully Connected).

L'abbiamo inserita come baseline. Volevamo dimostrare che, per immagini complesse come le MRI, una struttura che "appiattisce" i pixel perdendo la relazione spaziale tra di essi non è sufficiente. È stato il nostro punto di controllo per giustificare l'uso di modelli più avanzati.

- **ResNet-18 (Residual Network):** Una rete profonda che utilizza le cosiddette "connessioni residue" (skip connections). In medicina, i dettagli contano e le ResNet permettono di addestrare modelli profondi senza che le informazioni si "perdano" tra i layer. È stata scelta per la sua capacità di estrarre feature ad alta precisione, fungendo da modello "pesante" e performante della nostra analisi.

- **MobileNetV2:** Un'architettura ottimizzata che utilizza la Depthwise Separable Convolution per ridurre il numero di parametri.

L'abbiamo scelta perchè rappresenta l'equilibrio perfetto tra prestazioni e velocità. È il modello che è risultato più efficiente: veloce da addestrare ma capace di un'accuratezza sorprendente. In un'ottica di implementazione reale su tablet o dispositivi ospedalieri, è la soluzione tecnicamente più sostenibile.

3.3 La strategia del Transfer Learning

Un punto cardine della nostra metodologia è stato l'uso del **Transfer Learning**. Invece di far partire l'apprendimento da zero (un processo che richiederebbe una mole di dati immensa e tempi di calcolo proibitivi), abbiamo utilizzato modelli pre-addestrati su **ImageNet**.

Abbiamo sfruttato il fatto che i primi livelli di una rete imparano concetti visivi universali (linee, ombre, texture).

Per poi "*congelare*" questi livelli e *sostituire* solo l'ultimo strato (**il classificatore finale**) per adattarlo alle nostre 4 classi di Alzheimer. Questo ci ha permesso di ottenere un'alta precisione fin dalle prime epoche di addestramento, portando la conoscenza del "mondo reale" all'interno del "mondo medico".

3.4 Configurazione dell'addestramento

Per rendere l'apprendimento efficace e stabile, abbiamo adottato le seguenti scelte tecniche comuni a tutti i modelli:

- **Optimizer (Adam):** Abbiamo scelto Adam per la sua capacità di regolare automaticamente il tasso di apprendimento (learning rate), rendendo l'addestramento più fluido.
- **Loss Function (Cross-Entropy):** Lo standard per la classificazione multiclasse, che penalizza il modello in base a quanto la sua previsione si discosta dalla realtà.
- **Batch Size (32):** Un compromesso ideale per caricare abbastanza immagini in memoria GPU senza rallentare il sistema, garantendo aggiornamenti costanti dei pesi della rete.
- **Learning Rate Scheduler:** Abbiamo integrato ReduceLROnPlateau per evitare lo stallo dell'apprendimento. Se la Validation Loss non migliora per 2 epoche consecutive, il learning rate viene ridotto (fattore 0.1) per favorire la convergenza.
- **Early Stopping e Checkpointing:** Per prevenire l'overfitting, il modello salva i suoi pesi solo quando la Validation Loss migliora. Inoltre, se la rete non apprende nuove informazioni per 5 epoche (patience=5), il training si interrompe anticipatamente.

4 Esperimenti e Analisi delle Variabili Influenzanti

In questo capitolo descriviamo nel dettaglio l'ambiente di esecuzione e le configurazioni empiriche (iperparametri) utilizzate per addestrare i nostri modelli, garantendo la totale riproducibilità degli esperimenti condotti.

4.1 Ambiente di Sviluppo e Hardware

A causa delle limitazioni hardware locali e della natura computazionalmente intensiva delle architetture di Deep Learning scelte (in particolare la ResNet-18 e il Vision Transformer), gli esperimenti sono stati condotti in ambiente cloud. L'utilizzo di piattaforme dotate di acceleratori grafici (GPU) è stato fondamentale per abbattere i tempi di calcolo, specialmente durante la fase multiclasse che richiedeva l'elaborazione di tensori di dimensione $32 \times 3 \times 224 \times 224$ (Batch $\times$ Canali $\times$ Altezza $\times$ Larghezza).

4.2 Protocollo degli Esperimenti

Per garantire un confronto equo tra le diverse architetture, abbiamo standardizzato il protocollo di addestramento. Ogni esperimento è stato configurato con i seguenti iperparametri e meccanismi di controllo:

- **Algoritmo di Ottimizzazione:** È stato utilizzato l'ottimizzatore **Adam**, preferito per la sua capacità di adattare dinamicamente il tasso di apprendimento durante le epoche.
- **Learning Rate Scheduling:** Per ottimizzare la convergenza, abbiamo integrato la funzione `ReduceLROnPlateau`. Durante gli esperimenti, se la funzione di perdita sul set di validazione non mostrava miglioramenti per 2 epoche consecutive (`patience=2`), il learning rate veniva ridotto del 90% (`factor=0.1`).

- **Prevenzione dell'Overfitting (Early Stopping):** Tutti i modelli sono stati sottoposti a un monitoraggio rigoroso per evitare che memorizzassero i dati di training. Il loop di addestramento prevedeva un arresto anticipato (Early Stopping) qualora la Validation Loss non registrasse cali per 5 epoche di fila (patience=5). Inoltre, i pesi venivano salvati su disco (bestmodel.pth) esclusivamente in corrispondenza del minimo storico della Validation Loss.

4.3 Fasi di Addestramento e Fine-Tuning

L'attività sperimentale è stata strutturata in un percorso a complessità crescente, articolato in fasi distinte per validare l'efficacia delle diverse architetture e strategie di apprendimento:

4.3.1 Esperimento Baseline (MLP)

Il punto di partenza è consistito nell'addestramento from scratch (da zero) di un Multi-Layer Perceptron (MLP). Questa fase ha avuto lo scopo metodologico di stabilire una soglia minima di prestazione (baseline). L'esperimento ha confermato i limiti intrinseci delle reti neurali densamente connesse nell'elaborazione di dati visivi complessi: la perdita delle relazioni spaziali tra i pixel, causata dal processo di "appiattimento" (flattening) dell'input, ha prodotto risultati mediocri, giustificando la necessità di passare ad approcci basati su convoluzioni.

4.3.2 Configurazione della Classificazione Binaria (Fase 1)

Prima di affrontare la complessità del problema a quattro classi, è stata condotta una fase di validazione binaria volta a discriminare i soggetti sani (Non-Demented) da quelli affetti da patologia. In questo scenario, il modello ResNet-18 è stato configurato con un singolo neurone di output nella testata di classificazione.

- **Funzione di Perdita:** È stata adottata la **BCEWithLogitsLoss**, standard per le decisioni dicotomiche, poiché integra uno strato Sigmoidale interno che garantisce una stabilità numerica superiore durante il calcolo dei gradienti.
- **Strategia di Addestramento:** Si è utilizzato il Transfer Learning partendo dai pesi pre-addestrati su ImageNet, permettendo alla rete di focalizzarsi immediatamente sull'identificazione dei macro-pattern di atrofia cerebrale.

Questa fase è stata fondamentale per certificare la correttezza della pipeline di pre-processing e la capacità del modello di generalizzare su segnali clinici evidenti.




Figura 4.1: Matrice di confusione relativa ai risultati della Fase 1 (Classificazione Binaria).

Tabella 4.1: Confronto delle metriche di classificazione tra ResNet-18 e MLP Baseline.

Modello	Sano (Classe 0)			Affetto (Classe 1)			Accuracy
	Precision	Recall	F1-Score	Precision	Recall	F1-Score	
MLP Baseline	0.76	0.41	0.54	0.81	0.95	0.87	0.80
ResNet-18	0.96	0.91	0.94	0.97	0.99	0.98	0.96

I risultati ottenuti sul test set binario (Tabella 4.1) confermano l'efficacia del Transfer Learning applicato alle reti convoluzionali profonde rispetto a modelli densi tradizionali.




Figura 4.2: Plot aggiuntivi del modello MLP.




Figura 4.3: Plot aggiuntivi del modello resnet.

4.3.3 Esperimento Transfer Learning e Feature Extraction (Fase 2)

Per il task multiclasse, le architetture **MobileNetV2**, **ResNet-18** e il **Vision Transformer (ViT)** sono stati inizialmente impiegati come estrattori di caratteristiche fisici. In questa configurazione:

- I blocchi convoluzionali (o di attenzione nel caso del ViT) sono stati "congelati" (frozen) per preservare le capacità di riconoscimento di pattern visivi universali appresi su ImageNet.
- Solo il classificatore finale, riprogettato con 4 nodi di output, è stato addestrato per mappare tali caratteristiche verso le classi specifiche del dataset Alzheimer.

4.3.4 Ottimizzazione tramite Fine-Tuning

L'ultimo stadio del processo ha previsto il Fine-Tuning selettivo dei modelli. Una volta stabilizzati i pesi del classificatore finale, gli esperimenti prevedevano lo sblocco degli ultimi blocchi convoluzionali delle reti. Addestrando questi livelli con un learning rate estremamente basso, abbiamo permesso ai modelli di adattare i filtri visivi generici (linee, curve) alle micro-strutture specifiche delle risonanze magnetiche cerebrali. Questa tecnica è risultata determinante per migliorare la discriminazione nelle "zone grigie" della patologia, in particolare per distinguere lo stadio Very Mild Demented dal normale invecchiamento fisiologico.

Tabella 4.2: Confronto globale delle performance multiclasse: Precision, Recall e F1-Score pesati (discussi nel capitolo successivo).

Modello	Accuracy	Precision (Avg)	Recall (Avg)	F1-Score (Avg)
MLP Baseline	0.584	0.596	0.584	0.579
ViT_B_16	0.700	0.734	0.700	0.675
MobileNetV2	0.991	0.991	0.991	0.991
ResNet18	0.998	0.998	0.998	0.998

5 Valutazione dei Risultati e Analisi delle Performance

Dopo aver completato le fasi di addestramento, abbiamo testato la capacità di generalizzazione dei modelli sul Test Set. Questo sottoinsieme (pari al 15% del totale) è composto da immagini che le reti non avevano mai analizzato in precedenza, garantendo una valutazione imparziale e obiettiva delle reali prestazioni cliniche.

5.1 Analisi delle Metriche Globali

I risultati ottenuti con l'architettura **MobileNetV2** sono stati estremamente soddisfacenti, superando le aspettative iniziali per un modello così leggero:

- **Accuracy (Accuratezza):** con un valore di circa il 93%; significa che, su 100 scansioni MRI presentate al sistema, 93 vengono classificate correttamente nel loro esatto stadio di avanzamento.
- **Macro F1-Score:** con un 95% (il dato più importante) che a differenza dell'accuratezza semplice, ci indica che il modello è affidabile in modo uniforme su tutte e quattro le classi, non penalizzando le categorie meno rappresentate nel dataset.
- **Macro Precision (Precisione):** Abbiamo registrato un valore di circa il 94%. Questa metrica misura l'affidabilità delle previsioni: in termini pratici, significa che quando il sistema diagnostica a un paziente un determinato stadio di demenza, nel 94% dei casi la previsione è corretta. Un'alta precisione è vitale per ridurre al minimo i "falsi allarmi" (falsi positivi) che potrebbero causare stress ingiustificato.
- **Macro Recall (Sensibilità):** Il risultato ottenuto si attesta intorno al 93%. La Recall è la metrica più critica in ambito medico perché indica la capacità del modello di "non perdersi" i casi patologici. Un valore così alto garantisce la minimizzazione delle mancate diagnosi (falsi negativi), evitando che un paziente necessitante di cure venga erroneamente considerato sano.

5.2 Interpretazione della Confusion Matrix

La Confusion Matrix è lo strumento visivo che ci ha permesso di capire "dove" il modello sbaglia maggiormente.

Il sistema si è dimostrato molto efficace nell'identificare i casi di demenza Moderate e Mild, con una precisione vicina al 100%. Questo è un risultato fondamentale in uno scenario reale: è clinicamente vitale che un caso grave o moderato non venga mai scambiato per sano.




Figura 5.1: Risultati Classificazione Multi-Classe attraverso la matrice di confuzione.

5.2.1 La sfida della "Zona Grigia"

La "Zona Grigia" rappresenta quel confine incerto dove i parametri di normalità morfologica si sovrappongono a quelli della patologia, rendendo difficile una distinzione netta. Nel contesto del nostro progetto, si colloca esattamente tra la classe Non-Demented (Sano) e quella Very Mild Demented (Demenza molto lieve). L'analisi ha confermato che l'errore più comune risiede proprio qui: circa il 18% dei pazienti con demenza lievissima viene scambiato per sano. Dal punto di vista medico, questo errore è ampiamente comprensibile, poiché i segni iniziali di atrofia cerebrale sono così sottili da sovrapporsi ai normali segni di invecchiamento fisiologico discussi nel capitolo precedente.

5.3 La Curva ROC (One-vs-Rest)

Per confermare la robustezza del modello, abbiamo generato la curva ROC (Receiver Operating Characteristic) adottando un approccio One-vs-Rest per le classi multiple. Questa curva misura la capacità del classificatore di distinguere tra le classi al variare della soglia di confidenza. L'**Area Sotto la Curva (AUC)** è risultata prossima a 0.98 per quasi tutte le categorie. Questo valore eccezionale indica che il modello ha una probabilità altissima di assegnare un punteggio di confidenza superiore a un paziente effettivamente malato rispetto a uno sano, confermando l'affidabilità diagnostica della rete.




Figura 5.2: Curve ROC

5.4 Confronto tra le Architetture

Dal benchmark interno tra i vari approcci è emerso un quadro molto chiaro sulle prestazioni dei diversi algoritmi:

L'MLP (Baseline) ha mostrato limiti evidenti, faticando a superare il 60% di accuratezza. Questo conferma che la semplice intensità dei pixel "appiattita" non basta per una diagnosi accurata e che le dipendenze spaziali sono fondamentali.

La ResNet-18 ha ottenuto risultati molto solidi e stabili, confermandosi un eccellente estrattore di feature mediche, seppur con tempi di addestramento superiori.

Il Vision Transformer (ViT-B/16) ha dimostrato capacità di astrazione State-of-the-Art grazie al meccanismo di attenzione, ma l'enorme richiesta di memoria VRAM e i tempi di inferenza lo rendono difficilmente scalabile su hardware standard.

La **MobileNetV2** è risultata la vincitrice assoluta del nostro benchmark. Ha offerto prestazioni equiparabili alla ResNet e al ViT, ma con una velocità di esecuzione più che doppia e un numero di parametri drasticamente inferiore, rendendola la scelta clinica ideale per un'implementazione reale su dispositivi ospedalieri o tablet.

A coronamento del progetto, abbiamo sviluppato una **Demo Web** interattiva per tradurre i modelli addestrati in uno strumento pratico e accessibile. L'obiettivo dell'applicativo è simulare un reale scenario di supporto alla diagnostica clinica, permettendo a un utente (idealmente un medico o un ricercatore) di **caricare una scansione MRI** e ottenere un'**analisi predittiva in tempo reale**.

6.1 Funzionamento e Pipeline di Pre-processing

L'applicativo accetta in input immagini mediche nei formati standard. Una volta caricata la risonanza magnetica dall'utente, il sistema applica "**sotto il cofano**" la stessa rigorosa pipeline di trasformazione utilizzata durante la fase di addestramento: l'immagine viene ridimensionata a 224x224 pixel, convertita in formato tensoriale e normalizzata utilizzando i parametri di media e deviazione standard di ImageNet. Questa coerenza metodologica garantisce che il modello valuti la nuova immagine con gli stessi identici criteri con cui ha appreso a riconoscere i pattern morfologici.

6.2 Selezione Dinamica delle Architetture

Una delle funzionalità chiave della demo è la possibilità di scambiare e testare le diverse architetture neurali in **tempo reale**. Tramite un'interfaccia utente intuitiva, è possibile selezionare dinamicamente quale modello utilizzare per l'inferenza (ad esempio, passando dalla leggera *MobileNetV2* per una predizione rapida a una rete più profonda come la **ResNet-18**).

Al momento della selezione, il sistema gestisce dinamicamente il caricamento in memoria dei pesi definitivi (**.pth**) generati alla fine del nostro training loop. Questo permette un confronto "sul campo" tra i vari approcci senza dover riavviare l'ambiente di esecuzione.

6.3 Visualizzazione dei Risultati e Confidenza Clinica

L'applicativo è stato progettato per restituire un output che non sia una semplice "scatola nera", ma un reale strumento di supporto alle decisioni cliniche (**Decision Support System**). L'interfaccia fornisce:

Predizione Primaria: Il sistema indica in modo chiaro la classe diagnosticata (es. Mild Demented o Sano), offrendo un primo responso immediato.

Distribuzione delle Probabilità (Softmax): Invece di limitarsi a fornire una risposta "secca", la demo restituisce le percentuali di confidenza per tutti e quattro gli stadi della patologia. Il tensore di output della rete viene passato attraverso una funzione Softmax, trasformando i valori grezzi in percentuali leggibili (ad esempio: 75% Very Mild, 25% Mild, 0% sulle altre classi).

Questa visualizzazione probabilistica è fondamentale in ambito medico: permette al neurologo di comprendere il "ragionamento" della rete, di capire quanto il modello sia sicuro della propria diagnosi e di valutare le "Zone Grigie" (come i casi di confine tra invecchiamento sano e principio di demenza). In questo modo, l'Intelligenza Artificiale rispetta il suo ruolo di "secondo occhio" a supporto dell'esperienza del medico umano.




Figura 6.1: Prima pagina della Demo

Poi si aggiunge un'immagine dalla cartella raw e poi in base al modello scelto in alto a sinistra si avrà una classificazione multiclasse. Come ad esempio questa:




Figura 6.2: Prima Prova.

In questo caso abbiamo usato la MLP, ma non ha dato un risultato chiaro, però si è riuscito ad avere la percentuale più alta di classificazione dalla classe corretta.

Poi abbiamo fatto un esempio con la ResNet-18:




Figura 6.3: Seconda prova con ResNet-18.

Come si può notare dall'immagine da risultati molto più certi e corretti.

L'obiettivo di questo progetto non era semplicemente addestrare un algoritmo, ma progettare, validare e mettere in produzione un'intera pipeline di Deep Learning applicata a un problema medico reale e complesso come la diagnosi del morbo di Alzheimer. Attraverso un approccio metodologico rigoroso, abbiamo dimostrato l'efficacia delle reti neurali nell'estrazione di biomarcatori visivi da scansioni MRI, gestendo criticità tipiche del dominio clinico come lo sbilanciamento delle classi e la standardizzazione dell'input.

La divisione del problema in due step (Classificazione Binaria e Multiclasse) ci ha permesso di validare inizialmente la robustezza del nostro motore di addestramento, per poi affrontare con successo la vera sfida: la stadiazione del decadimento cognitivo. Lo sviluppo finale della Demo interattiva ha chiuso il cerchio, trasformando decine di ore di addestramento in uno strumento tangibile di supporto decisionale.

7.1 Considerazioni Finali sulle Architetture

Dal confronto tra i modelli sono emerse indicazioni chiare sul rapporto tra complessità architetturale e utilità clinica:

L'**approccio baseline (MLP)** ha confermato che le dipendenze spaziali dei pixel sono imprescindibili per l'analisi morfologica del cervello, ma ha dato risultati poco precisi.

Il **Transfer Learning** (utilizzando pesi pre-addestrati su ImageNet) si è rivelato la chiave di volta per far convergere modelli profondi come la ResNet-18 e il **Vision Transformer (ViT)** anche su un dominio specifico e ristretto come quello medico.

La **MobileNetV2** si è affermata come il modello più equilibrato: garantendo un F1-Score del 95% e tempi di inferenza ridottissimi, ha dimostrato che non è sempre necessario ricorrere all'architettura più pesante per ottenere risultati State-of-the-Art, rendendola la candidata ideale per l'implementazione in cliniche con risorse hardware limitate.

7.2 Sviluppi Futuri e Prospettive di Ricerca

Nonostante gli ottimi risultati ottenuti, il sistema attuale si basa esclusivamente sull'elaborazione bidimensionale di immagini strutturali. Per avvicinare ulteriormente questa tecnologia all'impiego in corsia, i futuri sviluppi del progetto dovrebbero concentrarsi su tre direttrici principali:

7.2.1 Integrazione Multimodale (Dati Clinici e Demografici):

Come discusso in precedenza, l'età e il livello socio-economico (SES) alterano profondamente il modo in cui i danni strutturali si traducono in sintomi cognitivi. Un modello futuro dovrà essere "multimodale": dovrà accettare in input non solo l'immagine MRI, ma anche un vettore contenente età, sesso, risultati dei test cognitivi (es. MMSE) e genetica del paziente. Solo fondendo dati visivi e tabulari l'IA potrà distinguere l'invecchiamento sano dall'atrofia patologica.

7.2.2 Explainable AI (Intelligenza Artificiale Spiegabile - XAI):

In medicina, la fiducia del medico verso l'algoritmo è fondamentale. Un upgrade indispensabile sarà l'implementazione di tecniche come la Grad-CAM (Gradient-weighted Class Activation Mapping). Questo strumento permetterebbe di sovrapporre una "mappa di calore" alla risonanza magnetica, evidenziando in rosso le esatte aree del cervello (es. l'ippocampo o i ventricoli) che hanno spinto la rete neurale a formulare quella specifica diagnosi.

7.2.3 Analisi Volumetrica 3D e Studi Longitudinali:

Il nostro progetto ha elaborato singole "fette" bidimensionali del cervello (scansioni 2D a 224x224 pixel). Il naturale step successivo sarà l'adozione di Reti Neurali Convoluzionali Tridimensionali (3D CNN) capaci di elaborare l'intero volume cranico nella sua interezza. Inoltre, spostando il focus dalla singola diagnosi statica all'analisi longitudinale, si potrebbe addestrare un modello a confrontare due MRI dello stesso paziente scattate a distanza di un anno, prevedendo così non solo lo stadio attuale, ma la velocità di progressione della malattia.

In conclusione, questo progetto dimostra il potenziale immenso del Deep Learning nell'imaging medico. L'Intelligenza Artificiale si conferma un "secondo occhio" instancabile, capace di scorgere schemi nascosti tra i pixel, ma il cui output deve sempre intrecciarsi con l'esperienza, l'empatia e la visione d'insieme del medico curante.

Documentazione di Progetto

Il codice sorgente, i modelli serializzati e la demo interattiva sono disponibili presso la repository ufficiale:

<https://github.com/MaccarroneAlessia/unict-dlcmm-Maccarrone-Brancaforte-Cassia>

Gruppo NeuroVisionDL

Alessia Maccarrone
matricola 1000084712

Martina Brancaforte
matricola 1000015074

Massimiliano Cassia
matricola 1000016487
